TD N° 4

K-NN

K-NN est un algorithme supervisé qui peut être utilisé pour la classification et la régression. Il prend comme paramètre K, le nombre de voisins les plus proches.

K-NN Algo

1. Choisir le nombre K en utilisant l'heuristique : $K \approx \sqrt{N}$ et K est impair
   - N est le nombre d'instances.
   - On prend K impair pour éviter une égalité dans le vote (pour la classification).
2. Calculer la distance entre X_{test} et tous les points du dataset.
3. Donner pour chaque point un rang en indexant de la plus petite distance à la plus grande (si même distance, donner le même rang).
4. Prendre les K plus proches voisins.
5. Si classification, faire un vote de majorité.
6. Si régression, faire la moyenne entre les labels des voisins.

C4.5

C4.5 est un algorithme supervisé qui génère un arbre de décision utilisé pour la classification. Il divise selon le gain_ratio.

Entropy $H(Y)$

L'entropie $H(Y)$ représente le degré de désordre, à quel point les labels sont mélangés. Plus elle est élevée, plus il y a un mélange :

$$H(Y) = -\sum_{y \in Y} P(y) \cdot \log_2(P(y))$$

- y représente une classe.
- Y représente toutes les classes.

Entropy $H(Y \mid X_i)$

L'entropie $H(Y)$ représente le désordre restant après avoir utilisé une information (attribut X_i) :

$$H(Y \mid X_i) = \sum_{x \in X_i} \frac{|D_x|}{|D|} \cdot \left[-\sum_{y \in Y} \frac{|D_{x,y}|}{|D_x|} \cdot \log_2 \left(\frac{|D_{x,y}|}{|D_x|} \right) \right]$$

- x une valeur de l'attribut X_i.
- X_i un attribut du data set.
- y représente une classe.
- Y représente toutes les classes.
- $|D|$ est le nombre d'instances.
- $|D_x|$ est le nombre d'instances avec x.
- $|D_{x,y}|$ est le nombre d'instances avec x et y.

gain(X_i)

Mesure combien un attribut (X_i) aide à réduire l'incertitude (l'entropie) dans la classification des données :

$$\text{gain}(X_i) = H(Y) - H(Y \mid X_i)$$

split_info(X_i)

Une métrique qui mesure l'information potentielle générée en divisant le data set en branche basées sur un attribut (X_i) :

$$\text{split_info}(X_i) = -\sum_{x \in X_i} \frac{|D_x|}{|D|} \cdot \log_2 \left(\frac{|D_x|}{|D|} \right)$$

gain_ratio(X_i)

Représente l'efficacité d'un critère, en équilibrant l'information gagnée par rapport à la complexité (le nombre de branches) qu'il crée :

$$\text{gain_ratio}(X_i) = \frac{\text{gain}(X_i)}{\text{split_info}(X_i)}$$

C4.5 Algo

1. Calcule l'entropie du label $H(Y)$.
2. Calcule le gain de tous les attributs gain(X).
3. Calcule le split_info de tous les attributs split_info(X).
4. Calcule le gain_ratio de tous les attributs gain_ratio(X).
5. Prendre le gain_ratio le plus grand et diviser le dataset par rapport à l'attribut.
6. Si aucune classe n'est mélangée, l'arbre de décision est fini.
7. Sinon, répéter le même traitement pour le sous-ensemble de données.

Exercice 1

Day	Outlook	Temperature	Humidity	Wind	PlayTennis?
1	Sunny	Hot	High	Light	No
2	Sunny	Hot	High	Strong	No
3	Overcast	Hot	High	Light	Yes
4	Rain	Mild	High	Light	Yes
5	Rain	Cool	Normal	Light	Yes
6	Rain	Cool	Normal	Strong	No
7	Overcast	Cool	Normal	Strong	Yes
8	Sunny	Mild	High	Light	No
9	Sunny	Cool	Normal	Light	Yes
10	Rain	Mild	Normal	Light	Yes
11	Sunny	Mild	Normal	Strong	Yes
12	Overcast	Mild	High	Strong	Yes
13	Overcast	Hot	Normal	Light	Yes
14	Rain	Mild	High	Strong	No

Utilisez le classifieur Naïve Bayes pour prédire si la personne jouera au tennis étant donné les nouvelles conditions suivantes : $X_{\text{test}} = (\text{sunny, cool, high, light})$

Calcule des probabilites priorie :

$$P(\text{Yes}) = \frac{9}{14} \quad , \quad P(\text{No}) = \frac{5}{14}$$

Calcule des probabilites conditionelle :

$$\begin{aligned} P(X_{\text{test}} \mid Y = \text{Yes}) &= P(x_1 = \text{sunny} \mid Y = \text{Yes}) \cdot P(x_2 = \text{cool} \mid Y = \text{Yes}) \cdot P(x_3 = \text{high} \mid Y = \text{Yes}) \cdot P(x_4 = \text{light} \mid Y = \text{Yes}) \\ &= \frac{2}{9} \cdot \frac{3}{9} \cdot \frac{3}{9} \cdot \frac{6}{9} \\ &= \frac{4}{243} \end{aligned}$$

$$\begin{aligned} P(X_{\text{test}} \mid Y = \text{No}) &= P(x_1 = \text{sunny} \mid Y = \text{No}) \cdot P(x_2 = \text{cool} \mid Y = \text{No}) \cdot P(x_3 = \text{high} \mid Y = \text{No}) \cdot P(x_4 = \text{light} \mid Y = \text{No}) \\ &= \frac{3}{5} \cdot \frac{1}{5} \cdot \frac{4}{5} \cdot \frac{2}{5} \\ &= \frac{24}{625} \end{aligned}$$

Calcule des numerateurs :

$$\begin{aligned} \text{Numerateur(Yes)} &= P(X_{\text{test}} \mid Y = \text{Oui}) \cdot P(\text{Yes}) = \frac{4}{243} \cdot \frac{9}{14} = 0.010 \\ \text{Numerateur(No)} &= P(X_{\text{test}} \mid Y = \text{No}) \cdot P(\text{No}) = \frac{24}{625} \cdot \frac{5}{14} = 0.013 \end{aligned}$$

Puisque Numerateur(No) = 0.013 > Numerateur(Yes) = 0.010 le classifieur Naïve Bayes prédit la classe No.

Conclusion : Selon les conditions de test (X_{text} = (sunny , cool , high , light)) l'algorithme prédit que la personne ne jouera pas au tennis.

Proposer une mesure de similarité entre les instances :

On va utiliser **la distance euclidienne** mais avant ca on doit transformer les string en chiffre avec **label encoding** :

Day	**Outlook**	**Temperature**	**Humidity**	**Wind**	**PlayTennis?**
1	1	1	1	1	No
2	1	1	1	2	No
3	2	1	1	1	Yes
4	3	2	1	1	Yes
5	3	3	2	1	Yes
6	3	3	2	2	No
7	2	3	2	2	Yes
8	1	2	1	1	No
9	1	3	2	1	Yes
10	3	2	2	1	Yes
11	1	2	2	2	Yes
12	2	2	1	2	Yes
13	2	1	2	1	Yes
14	3	2	1	2	No

Appliquer l'algorithme K-NN :

Pour choisir K on utilisera heuristique $K \approx \sqrt{N}$:

$$\sqrt{N} = \sqrt{14} = 3.74 \Rightarrow K = 3$$

On calcule les distances et rangs de tout les points avec $X_{\text{text}} = (1, 3, 1, 1)$

Outlook	**Temp**	**Humidity**	**Wind**	**Play?**	**Distance**	**Rang**
1	1	1	1	No	$\sqrt{(1-1)^2+(3-1)^2+(1-1)^2+(1-1)^2} = 2$	3
1	1	1	2	No	$\sqrt{(1-1)^2+(3-1)^2+(1-1)^2+(1-2)^2} = 2.23$	4
2	1	1	1	Yes	$\sqrt{(1-2)^2+(3-1)^2+(1-1)^2+(1-1)^2} = 2.23$	4
3	2	1	1	Yes	$\sqrt{(1-3)^2+(3-2)^2+(1-1)^2+(1-1)^2} = 2.23$	4
3	3	2	1	Yes	$\sqrt{(1-3)^2+(3-3)^2+(1-2)^2+(1-1)^2} = 2.23$	4
3	3	2	2	No	$\sqrt{(1-3)^2+(3-3)^2+(1-2)^2+(1-2)^2} = 2.44$	5
2	3	2	2	Yes	$\sqrt{(1-2)^2+(3-3)^2+(1-2)^2+(1-2)^2} = 1.73$	2
1	2	1	1	No	$\sqrt{(1-1)^2+(3-2)^2+(1-1)^2+(1-1)^2} = 1$	1
1	3	2	1	Yes	$\sqrt{(1-1)^2+(3-3)^2+(1-2)^2+(1-1)^2} = 1$	1
3	2	2	1	Yes	$\sqrt{(1-3)^2+(3-2)^2+(1-2)^2+(1-1)^2} = 2.44$	5
1	2	2	2	Yes	$\sqrt{(1-1)^2+(3-2)^2+(1-2)^2+(1-2)^2} = 1.73$	2
2	2	1	2	Yes	$\sqrt{(1-2)^2+(3-2)^2+(1-1)^2+(1-2)^2} = 1.73$	2
2	1	2	1	Yes	$\sqrt{(1-2)^2+(3-1)^2+(1-2)^2+(1-1)^2} = 2.44$	5
3	2	1	2	No	$\sqrt{(1-3)^2+(3-2)^2+(1-1)^2+(1-2)^2} = 2.44$	5

Les trois voisins les plus proches sont les jours { 7 : Yes , 8 : No, 9 : Yes } par vote on a Yes > No donc l'algorithme predit la class Yes et que X_{test} jouera au tenis.

Exercice 3

Departement	Statut	Age	Salaire	Nombre
ventes	senior	31..35	46k..50k	30
ventes	junior	26..30	26k..30k	40
ventes	junior	31..35	31k..35k	40
systemes	junior	21..25	46k..50k	20
systemes	senior	31..35	66k..70k	5
systemes	junior	26..30	46k..50k	3
systemes	senior	41..45	66k..70k	3
marketing	senior	36..40	46k..50k	10
marketing	junior	31..35	41k..45k	4
secretariat	senior	46..50	36k..40k	4
secretariat	junior	26..30	26k..30k	6

On prend l'attribut Statut comme attribut de class engendrer l'arbre de decision sans tenir compte de l'attribut nombre.

Calcule de l'entropie de class status $H(\text{statut})$:

$$-\sum_{i=1}^{C=2} P(y_i) \cdot \log_2 (P(y_i)) = -\left[\underbrace{\frac{5}{11} \cdot \log_2 \left(\frac{5}{11}\right)}_{y_1=\text{senior}} + \underbrace{\frac{6}{11} \cdot \log_2 \left(\frac{6}{11}\right)}_{y_2=\text{junior}}\right] = 0.994$$

(coleur : junior senior)

Calcule $\text{gain}(\text{dep}) = H(\text{statut}) - H(\text{statut}|\text{dep})$:

$$\begin{aligned}
H(\text{statut}|\text{dep}) &= \sum_{x \in X} \frac{|D_x|}{|D|} \left(-\sum_{i=1}^{C=2} \frac{|D_{x,y}|}{|D_x|} \cdot \log_2 \left(\frac{|D_{x,y}|}{|D_x|} \right) \right) \\
&= \frac{3}{11} \cdot \left(-\left[\frac{2}{3} \cdot \log_2 \left(\frac{2}{3}\right) + \frac{1}{3} \cdot \log_2 \left(\frac{1}{3}\right) \right] \right) \quad \text{ventes} \\
&+ \frac{4}{11} \cdot \left(-\left[\frac{2}{4} \cdot \log_2 \left(\frac{2}{4}\right) + \frac{2}{4} \cdot \log_2 \left(\frac{2}{4}\right) \right] \right) \quad \text{systemes} \\
&+ \frac{2}{11} \cdot \left(-\left[\frac{1}{2} \cdot \log_2 \left(\frac{1}{2}\right) + \frac{1}{2} \cdot \log_2 \left(\frac{1}{2}\right) \right] \right) \quad \text{marketing} \\
&+ \frac{2}{11} \cdot \left(-\left[\frac{1}{2} \cdot \log_2 \left(\frac{1}{2}\right) + \frac{1}{2} \cdot \log_2 \left(\frac{1}{2}\right) \right] \right) \quad \text{secretariat} \\
&= 0.977
\end{aligned}$$

$$\text{gain}(\text{dep}) = H(\text{statut}) - H(\text{statut}|\text{dep}) = 0.994 - 0.977 = 0.017$$

Calcule gain(age) $= H(\text{statut}) - H(\text{statut}|\text{age})$:

$$
\begin{aligned}
H(\text{statut}|\text{age}) &= \sum_{x \in X} \frac{|D_x|}{|D|} \left(- \sum_{i=1}^{C=2} \frac{|D_{x,y}|}{|D_x|} \cdot \log_2 \left(\frac{|D_{x,y}|}{|D_x|} \right) \right) \\
&= \frac{4}{11} \cdot \left(- \left[\frac{2}{4} \cdot \log_2 \left(\frac{2}{4} \right) + \frac{2}{4} \cdot \log_2 \left(\frac{2}{4} \right) \right] \right) \quad 31..35 \\
&+ \frac{3}{11} \cdot \left(- \left[\frac{3}{3} \cdot \log_2 \left(\frac{3}{3} \right) \right] \right) \quad 26..30 \\
&+ \frac{1}{11} \cdot \left(- \left[\frac{1}{1} \cdot \log_2 \left(\frac{1}{1} \right) \right] \right) \quad 21..25 \\
&+ \frac{1}{11} \cdot \left(- \left[\frac{1}{1} \cdot \log_2 \left(\frac{1}{1} \right) \right] \right) \quad 41..45 \\
&+ \frac{1}{11} \cdot \left(- \left[\frac{1}{1} \cdot \log_2 \left(\frac{1}{1} \right) \right] \right) \quad 36..40 \\
&+ \frac{1}{11} \cdot \left(- \left[\frac{1}{1} \cdot \log_2 \left(\frac{1}{1} \right) \right] \right) \quad 46..50 \\
&= 0.363
\end{aligned}
$$

$$\text{gain(age)} = H(\text{statut}) - H(\text{statut}|\text{age}) = 0.994 - 0.363 = 0.631$$

Calcule gain(salaire) $= H(\text{statut}) - H(\text{statut}|\text{salaire})$:

$$
\begin{aligned}
H(\text{statut}|\text{salaire}) &= \sum_{x \in X} \frac{|D_x|}{|D|} \left(- \sum_{i=1}^{C=2} \frac{|D_{x,y}|}{|D_x|} \cdot \log_2 \left(\frac{|D_{x,y}|}{|D_x|} \right) \right) \\
&= \frac{4}{11} \cdot \left(- \left[\frac{2}{4} \cdot \log_2 \left(\frac{2}{4} \right) + \frac{2}{4} \cdot \log_2 \left(\frac{2}{4} \right) \right] \right) \quad 46\text{k}..50\text{k} \\
&+ \frac{2}{11} \cdot \left(- \left[\frac{2}{2} \cdot \log_2 \left(\frac{2}{2} \right) \right] \right) \quad 26\text{k}..30\text{k} \\
&+ \frac{1}{11} \cdot \left(- \left[\frac{1}{1} \cdot \log_2 \left(\frac{1}{1} \right) \right] \right) \quad 31\text{k}..35\text{k} \\
&+ \frac{2}{11} \cdot \left(- \left[\frac{2}{2} \cdot \log_2 \left(\frac{2}{2} \right) \right] \right) \quad 66\text{k}..70\text{k} \\
&+ \frac{1}{11} \cdot \left(- \left[\frac{1}{1} \cdot \log_2 \left(\frac{1}{1} \right) \right] \right) \quad 41\text{k}..45\text{k} \\
&+ \frac{1}{11} \cdot \left(- \left[\frac{1}{1} \cdot \log_2 \left(\frac{1}{1} \right) \right] \right) \quad 36\text{k}..40\text{k} \\
&= 0.363
\end{aligned}
$$

$$\text{gain(salaire)} = H(\text{statut}) - H(\text{statut}|\text{salaire}) = 0.994 - 0.363 = 0.631$$

Calcule split_info(dep) :

$$
\begin{aligned}
\text{split_info(dep)} &= -\sum_{x \in X} \frac{|D_x|}{|D|} \cdot \log_2 \left(\frac{|D_x|}{|D|} \right) \\
&= -\left(\frac{3}{11} \cdot \log_2 \left(\frac{3}{11} \right) \quad \text{ventes} \right. \\
&+ \frac{4}{11} \cdot \log_2 \left(\frac{4}{11} \right) \quad \text{systemes} \\
&+ \frac{2}{11} \cdot \log_2 \left(\frac{2}{11} \right) \quad \text{marketing} \\
&+ \left. \frac{2}{11} \cdot \log_2 \left(\frac{2}{11} \right) \right) \quad \text{secretariat} \\
&= 1.936
\end{aligned}
$$

Calcule split_info(age) :

$$
\begin{aligned}
\text{split_info(age)} &= -\sum_{x \in X} \frac{|D_x|}{|D|} \cdot \log_2 \left(\frac{|D_x|}{|D|} \right) \\
&= -\left(\frac{4}{11} \cdot \log_2 \left(\frac{4}{11} \right) \quad 31..35 \right. \\
&+ \frac{3}{11} \cdot \log_2 \left(\frac{3}{11} \right) \quad 26..30 \\
&+ \frac{1}{11} \cdot \log_2 \left(\frac{1}{11} \right) \quad 21..25 \\
&+ \frac{1}{11} \cdot \log_2 \left(\frac{1}{11} \right) \quad 41..45 \\
&+ \frac{1}{11} \cdot \log_2 \left(\frac{1}{11} \right) \quad 36..40 \\
&+ \left. \frac{1}{11} \cdot \log_2 \left(\frac{1}{11} \right) \right) \quad 46..50 \\
&= 2.299
\end{aligned}
$$

Calcule split_info(salaire) :

$$
\begin{aligned}
\text{split_info(salaire)} &= -\sum_{x \in X} \frac{|D_x|}{|D|} \cdot \log_2\left(\frac{|D_x|}{|D|}\right) \\
&= -\left(\frac{4}{11} \cdot \log_2\left(\frac{4}{11}\right)\right. \quad \text{46k..50k} \\
&+ \frac{2}{11} \cdot \log_2\left(\frac{2}{11}\right) \quad \text{26k..30k} \\
&+ \frac{1}{11} \cdot \log_2\left(\frac{1}{11}\right) \quad \text{31k..35k} \\
&+ \frac{2}{11} \cdot \log_2\left(\frac{2}{11}\right) \quad \text{66k..70k} \\
&+ \frac{1}{11} \cdot \log_2\left(\frac{1}{11}\right) \quad \text{41k..45k} \\
&+ \left.\frac{1}{11} \cdot \log_2\left(\frac{1}{11}\right)\right) \quad \text{36k..40k} \\
&= 2.368
\end{aligned}
$$

Calcule gain_ratio(dep) :

$$\text{gain_ratio(dep)} = \frac{\text{gain(dep)}}{\text{split_info(dep)}} = \frac{0.017}{1.936} = 8.780 \times 10^{-3}$$

Calcule gain_ratio(age) :

$$\text{gain_ratio(age)} = \frac{\text{gain(age)}}{\text{split_info(age)}} = \frac{0.631}{2.299} = 0.274$$

Calcule gain_ratio(salaire) :

$$\text{gain_ratio(salaire)} = \frac{\text{gain(salaire)}}{\text{split_info(salaire)}} = \frac{0.631}{2.368} = 0.266$$

Arbre de decision de la premiere iteration :

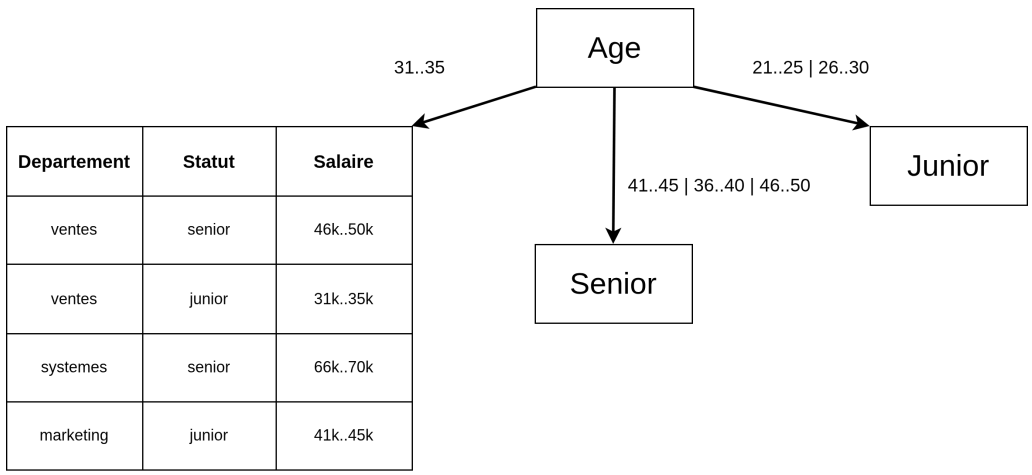

Departement	Statut	Salaire
ventes	senior	46k..50k
ventes	junior	31k..35k
systemes	senior	66k..70k
marketing	junior	41k..45k

Calcule de l'entropie de class status $H(\text{statut})$:

$$-\sum_{i=1}^{C=2} P(y_i) \cdot \log_2 (P(y_i)) = -\left[\underbrace{\frac{2}{4} \cdot \log_2 \left(\frac{2}{4}\right)}_{y_1=\text{senior}} + \underbrace{\frac{2}{4} \cdot \log_2 \left(\frac{2}{4}\right)}_{y_2=\text{junior}}\right] = 1$$

Calcule $\text{gain}(\text{dep}) = H(\text{statut}) - H(\text{statut}|\text{dep})$:

$$\begin{aligned}
H(\text{statut}|\text{dep}) &= \sum_{x \in X} \frac{|D_x|}{|D|} \left(-\sum_{i=1}^{C=2} \frac{|D_{x,y}|}{|D_x|} \cdot \log_2 \left(\frac{|D_{x,y}|}{|D_x|}\right)\right) \\
&= \frac{2}{4} \cdot \left(-\left[\frac{1}{2} \cdot \log_2 \left(\frac{1}{2}\right) + \frac{1}{2} \cdot \log_2 \left(\frac{1}{2}\right)\right]\right) \quad \text{ventes} \\
&+ \frac{1}{4} \cdot \left(-\left[\frac{1}{1} \cdot \log_2 \left(\frac{1}{1}\right)\right]\right) \quad \text{systemes} \\
&+ \frac{1}{4} \cdot \left(-\left[\frac{1}{1} \cdot \log_2 \left(\frac{1}{1}\right)\right]\right) \quad \text{marketing} \\
&= 0.5
\end{aligned}$$

$$\text{gain}(\text{dep}) = H(\text{statut}) - H(\text{statut}|\text{dep}) = 1 - 0.5 = 0.5$$

Calcule $\text{gain}(\text{salaire}) = H(\text{statut}) - H(\text{statut}|\text{salaire})$:

$$\begin{aligned}
H(\text{statut}|\text{salaire}) &= \sum_{x \in X} \frac{|D_x|}{|D|} \left(-\sum_{i=1}^{C=2} \frac{|D_{x,y}|}{|D_x|} \cdot \log_2 \left(\frac{|D_{x,y}|}{|D_x|}\right)\right) \\
&= \frac{1}{4} \cdot \left(-\left[\frac{1}{1} \cdot \log_2 \left(\frac{1}{1}\right)\right]\right) \quad \text{46k..50k} \\
&+ \frac{1}{4} \cdot \left(-\left[\frac{1}{1} \cdot \log_2 \left(\frac{1}{1}\right)\right]\right) \quad \text{31k..35k} \\
&+ \frac{1}{4} \cdot \left(-\left[\frac{1}{1} \cdot \log_2 \left(\frac{1}{1}\right)\right]\right) \quad \text{66k..70k} \\
&+ \frac{1}{4} \cdot \left(-\left[\frac{1}{1} \cdot \log_2 \left(\frac{1}{1}\right)\right]\right) \quad \text{41k..45k} \\
&= 0
\end{aligned}$$

$$\text{gain}(\text{salaire}) = H(\text{statut}) - H(\text{statut}|\text{salaire}) = 1 - 0 = 1$$

Calcule split_info(dep) :

$$\begin{aligned}
\text{split_info(dep)} &= -\sum_{x \in X} \frac{|D_x|}{|D|} \cdot \log_2 \left(\frac{|D_x|}{|D|} \right) \\
&= -\left(\frac{2}{4} \cdot \log_2 \left(\frac{2}{4} \right) \quad \text{ventes} \right. \\
&+ \frac{1}{4} \cdot \log_2 \left(\frac{1}{4} \right) \quad \text{systemes} \\
&+ \left. \frac{1}{4} \cdot \log_2 \left(\frac{1}{4} \right) \right] \quad \text{marketing} \\
&= 1.5
\end{aligned}$$

Calcule split_info(salaire) :

$$\begin{aligned}
\text{split_info(salaire)} &= -\sum_{x \in X} \frac{|D_x|}{|D|} \cdot \log_2 \left(\frac{|D_x|}{|D|} \right) \\
&= -\left[\frac{1}{4} \cdot \log_2 \left(\frac{1}{4} \right) \quad \text{46k..50k} \right. \\
&+ \frac{1}{4} \cdot \log_2 \left(\frac{1}{4} \right) \quad \text{31k..35k} \\
&+ \frac{1}{4} \cdot \log_2 \left(\frac{1}{4} \right) \quad \text{66k..70k} \\
&+ \left. \frac{1}{4} \cdot \log_2 \left(\frac{1}{4} \right) \right] \quad \text{41k..45k} \\
&= 2
\end{aligned}$$

Calcule gain_ratio(dep) :

$$\text{gain_ratio(dep)} = \frac{\text{gain(dep)}}{\text{split_info(dep)}} = \frac{0.5}{1.5} = 0.333$$

Calcule gain_ratio(salaire) :

$$\text{gain_ratio(salaire)} = \frac{\text{gain(salaire)}}{\text{split_info(salaire)}} = \frac{1}{2} = 0.5$$

Arbre de decision de la deuxieme iteration :

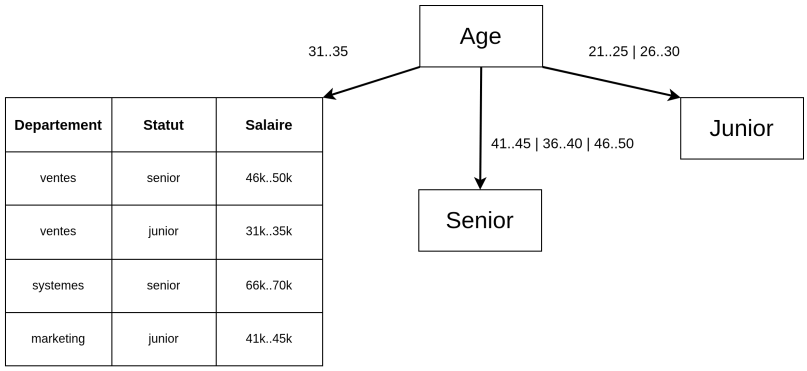

Departement	Statut	Salaire
ventes	senior	46k..50k
ventes	junior	31k..35k
systemes	senior	66k..70k
marketing	junior	41k..45k

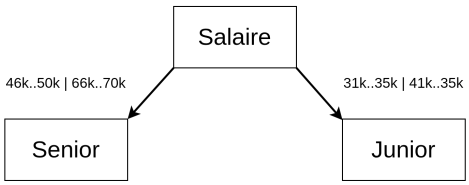

Comment modifier l'algorithme de l'arbre de décision pour prendre en compte le nombre d'occurrence de l'instance ?

La Solution : Au lieu de compter une instance comme 1, on compte sa fréquence lorsqu'on calcule les probabilités.

Déduire l'arbre de décision engendré de l'exécution de l'algorithme modifie :

Calcule de l'entropie de class status $H(\text{statut})$:

$$-\sum_{i=1}^{C=2} P(y_i)\cdot\log_2\left(P(y_i)\right) = -\left[\underbrace{\frac{52}{165}\cdot\log_2\left(\frac{52}{165}\right)}_{y_1=\text{senior}} + \underbrace{\frac{113}{165}\cdot\log_2\left(\frac{113}{165}\right)}_{y_2=\text{junior}}\right] = 0.899$$

Calcule $\text{gain}(\text{dep}) = H(\text{statut}) - H(\text{statut}|\text{dep})$:

$$\begin{aligned}
H(\text{statut}|\text{dep}) &= \sum_{x\in X}\frac{|D_x|}{|D|}\left(-\sum_{i=1}^{C=2}\frac{|D_{x,y}|}{|D_x|}\cdot\log_2\left(\frac{|D_{x,y}|}{|D_x|}\right)\right)\\
&= \frac{110}{165}\cdot\left(-\left[\frac{80}{110}\cdot\log_2\left(\frac{80}{110}\right)+\frac{30}{110}\cdot\log_2\left(\frac{30}{110}\right)\right]\right) \quad \text{ventes}\\
&+\frac{31}{165}\cdot\left(-\left[\frac{23}{31}\cdot\log_2\left(\frac{23}{31}\right)+\frac{8}{31}\cdot\log_2\left(\frac{8}{31}\right)\right]\right) \quad \text{systemes}\\
&+\frac{14}{165}\cdot\left(-\left[\frac{4}{14}\cdot\log_2\left(\frac{4}{14}\right)+\frac{10}{14}\cdot\log_2\left(\frac{10}{14}\right)\right]\right) \quad \text{marketing}\\
&+\frac{10}{165}\cdot\left(-\left[\frac{6}{10}\cdot\log_2\left(\frac{6}{10}\right)+\frac{4}{10}\cdot\log_2\left(\frac{4}{10}\right)\right]\right) \quad \text{secretariat}\\
&= 0.850
\end{aligned}$$

$$\text{gain}(\text{dep}) = H(\text{statut}) - H(\text{statut}|\text{dep}) = 0.899 - 0.850 = 0.049$$

Calcule $\text{gain}(\text{age}) = H(\text{statut}) - H(\text{statut}|\text{age})$:

$$\begin{aligned}
H(\text{statut}|\text{age}) &= \sum_{x\in X}\frac{|D_x|}{|D|}\left(-\sum_{i=1}^{C=2}\frac{|D_{x,y}|}{|D_x|}\cdot\log_2\left(\frac{|D_{x,y}|}{|D_x|}\right)\right)\\
&= \frac{79}{165}\cdot\left(-\left[\frac{44}{79}\cdot\log_2\left(\frac{44}{79}\right)+\frac{35}{79}\cdot\log_2\left(\frac{35}{79}\right)\right]\right) \quad 31..35\\
&+\frac{49}{165}\cdot\left(-\left[\frac{49}{49}\cdot\log_2\left(\frac{49}{49}\right)\right]\right) \quad 26..30\\
&+\frac{20}{165}\cdot\left(-\left[\frac{20}{20}\cdot\log_2\left(\frac{20}{20}\right)\right]\right) \quad 21..25\\
&+\frac{3}{165}\cdot\left(-\left[\frac{3}{3}\cdot\log_2\left(\frac{3}{3}\right)\right]\right) \quad 41..45\\
&+\frac{10}{165}\cdot\left(-\left[\frac{10}{10}\cdot\log_2\left(\frac{10}{10}\right)\right]\right) \quad 36..40\\
&+\frac{4}{165}\cdot\left(-\left[\frac{4}{4}\cdot\log_2\left(\frac{4}{4}\right)\right]\right) \quad 46..50\\
&= 0.474
\end{aligned}$$

$$\text{gain}(\text{age}) = H(\text{statut}) - H(\text{statut}|\text{age}) = 0.899 - 0.474 = 0.425$$

Calcule gain(salaire) $= H(\text{statut}) - H(\text{statut}|\text{salaire})$:

$$
\begin{aligned}
H(\text{statut}|\text{salaire}) &= \sum_{x \in X} \frac{|D_x|}{|D|} \left(- \sum_{i=1}^{C=2} \frac{|D_{x,y}|}{|D_x|} \cdot \log_2 \left(\frac{|D_{x,y}|}{|D_x|} \right) \right) \\
&= \frac{63}{165} \cdot \left(- \left[\frac{23}{63} \cdot \log_2 \left(\frac{23}{63} \right) + \frac{40}{63} \cdot \log_2 \left(\frac{40}{63} \right) \right] \right) \quad \text{46k..50k} \\
&+ \frac{46}{165} \cdot \left(- \left[\frac{46}{46} \cdot \log_2 \left(\frac{46}{46} \right) \right] \right) \quad \text{26k..30k} \\
&+ \frac{40}{165} \cdot \left(- \left[\frac{40}{40} \cdot \log_2 \left(\frac{40}{40} \right) \right] \right) \quad \text{31k..35k} \\
&+ \frac{8}{165} \cdot \left(- \left[\frac{8}{8} \cdot \log_2 \left(\frac{8}{8} \right) \right] \right) \quad \text{66k..70k} \\
&+ \frac{4}{165} \cdot \left(- \left[\frac{4}{4} \cdot \log_2 \left(\frac{4}{4} \right) \right] \right) \quad \text{41k..45k} \\
&+ \frac{4}{165} \cdot \left(- \left[\frac{4}{4} \cdot \log_2 \left(\frac{4}{4} \right) \right] \right) \quad \text{36k..40k} \\
&= 0.361
\end{aligned}
$$

$$
\text{gain(salaire)} = H(\text{statut}) - H(\text{statut}|\text{salaire}) = 0.899 - 0.361 = 0.538
$$

Calcule split_info(dep) :

$$
\begin{aligned}
\text{split_info(dep)} &= - \sum_{x \in X} \frac{|D_x|}{|D|} \cdot \log_2 \left(\frac{|D_x|}{|D|} \right) \\
&= - \left(\frac{110}{165} \cdot \log_2 \left(\frac{110}{165} \right) \right. \quad \text{ventes} \\
&+ \frac{31}{165} \cdot \log_2 \left(\frac{31}{165} \right) \quad \text{systemes} \\
&+ \frac{14}{165} \cdot \log_2 \left(\frac{14}{165} \right) \quad \text{marketing} \\
&+ \left. \frac{10}{165} \cdot \log_2 \left(\frac{10}{165} \right) \right) \quad \text{secretariat} \\
&= 1.390
\end{aligned}
$$

Calcule split_info(age) :

$$
\begin{aligned}
\text{split_info(age)} &= -\sum_{x \in X} \frac{|D_x|}{|D|} \cdot \log_2 \left(\frac{|D_x|}{|D|} \right) \\
&= -\left(\frac{79}{165} \cdot \log_2 \left(\frac{79}{165} \right) \quad 31..35 \right. \\
&+ \frac{49}{165} \cdot \log_2 \left(\frac{49}{165} \right) \quad 26..30 \\
&+ \frac{20}{165} \cdot \log_2 \left(\frac{20}{165} \right) \quad 21..25 \\
&+ \frac{3}{165} \cdot \log_2 \left(\frac{3}{165} \right) \quad 41..45 \\
&+ \frac{10}{165} \cdot \log_2 \left(\frac{10}{165} \right) \quad 36..40 \\
&+ \left. \frac{4}{165} \cdot \log_2 \left(\frac{4}{165} \right) \right) \quad 46..50 \\
&= 1.878
\end{aligned}
$$

Calcule split_info(salaire) :

$$
\begin{aligned}
\text{split_info(salaire)} &= -\sum_{x \in X} \frac{|D_x|}{|D|} \cdot \log_2 \left(\frac{|D_x|}{|D|} \right) \\
&= -\left(\frac{63}{165} \cdot \log_2 \left(\frac{63}{165} \right) \quad 46\text{k}..50\text{k} \right. \\
&+ \frac{46}{165} \cdot \log_2 \left(\frac{46}{165} \right) \quad 26\text{k}..30\text{k} \\
&+ \frac{40}{165} \cdot \log_2 \left(\frac{40}{165} \right) \quad 31\text{k}..35\text{k} \\
&+ \frac{8}{165} \cdot \log_2 \left(\frac{8}{165} \right) \quad 66\text{k}..70\text{k} \\
&+ \frac{4}{165} \cdot \log_2 \left(\frac{4}{165} \right) \quad 41\text{k}..45\text{k} \\
&+ \left. \frac{4}{165} \cdot \log_2 \left(\frac{4}{165} \right) \right) \quad 36\text{k}..40\text{k} \\
&= 1.481
\end{aligned}
$$

Calcule gain_ratio(dep) :

$$\text{gain_ratio(dep)} = \frac{\text{gain(dep)}}{\text{split_info(dep)}} = \frac{0.049}{1.390} = 0.035$$

Calcule gain_ratio(age) :

$$\text{gain_ratio(age)} = \frac{\text{gain(age)}}{\text{split_info(age)}} = \frac{0.425}{1.878} = 0.226$$

Calcule gain_ratio(salaire) :

$$\text{gain_ratio(salaire)} = \frac{\text{gain(salaire)}}{\text{split_info(salaire)}} = \frac{0.538}{1.481} = 0.363$$

Arbre de decision de la premiere iteration :

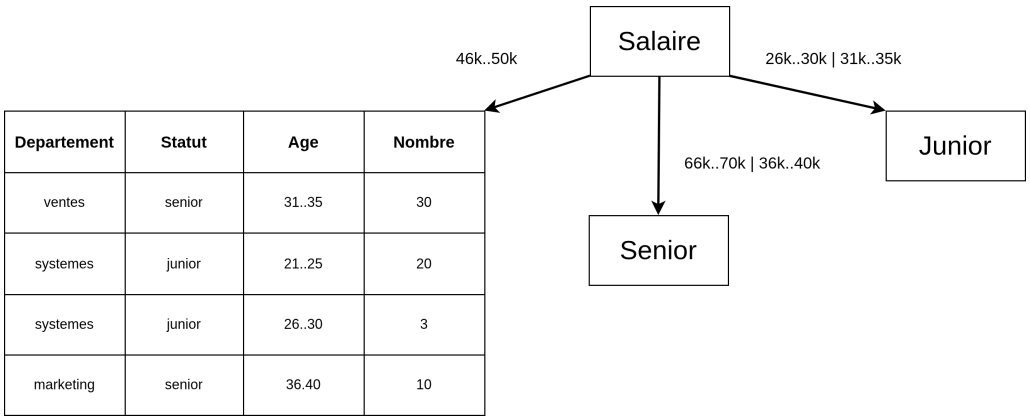

Departement	Statut	Age	Nombre
ventes	senior	31..35	30
systemes	junior	21..25	20
systemes	junior	26..30	3
marketing	senior	36.40	10

Calcule de l'entropie de class status $H(\text{statut})$:

$$-\sum_{i=1}^{C=2} P(y_i) \cdot \log_2 (P(y_i)) = -\left[\underbrace{\frac{40}{63} \cdot \log_2 \left(\frac{40}{63}\right)}_{y_1=\text{senior}} + \underbrace{\frac{23}{63} \cdot \log_2 \left(\frac{23}{63}\right)}_{y_2=\text{junior}}\right] = 0.946$$

Calcule $\text{gain(dep)} = H(\text{statut}) - H(\text{statut}|\text{dep})$:

$$\begin{aligned}
H(\text{statut}|\text{dep}) &= \sum_{x \in X} \frac{|D_x|}{|D|} \left(-\sum_{i=1}^{C=2} \frac{|D_{x,y}|}{|D_x|} \cdot \log_2 \left(\frac{|D_{x,y}|}{|D_x|} \right) \right) \\
&= \frac{30}{63} \cdot \left(-\left[\frac{30}{30} \cdot \log_2 \left(\frac{30}{30} \right) \right] \right) \quad \text{ventes} \\
&+ \frac{23}{63} \cdot \left(-\left[\frac{23}{23} \cdot \log_2 \left(\frac{23}{23} \right) \right] \right) \quad \text{systemes} \\
&+ \frac{10}{63} \cdot \left(-\left[\frac{10}{10} \cdot \log_2 \left(\frac{10}{10} \right) \right] \right) \quad \text{marketing} \\
&= 0
\end{aligned}$$

$$\text{gain(dep)} = H(\text{statut}) - H(\text{statut}|\text{dep}) = 0.946 - 0 = 0.946$$

Calcule gain(age) $= H(\text{statut}) - H(\text{statut}|\text{age})$:

$$
\begin{aligned}
H(\text{statut}|\text{age}) &= \sum_{x \in X} \frac{|D_x|}{|D|} \left(- \sum_{i=1}^{C=2} \frac{|D_{x,y}|}{|D_x|} \cdot \log_2 \left(\frac{|D_{x,y}|}{|D_x|} \right) \right) \\
&= \frac{30}{63} \cdot \left(- \left[\frac{30}{30} \cdot \log_2 \left(\frac{30}{30} \right) \right] \right) \quad 31..35 \\
&+ \frac{3}{63} \cdot \left(- \left[\frac{3}{3} \cdot \log_2 \left(\frac{3}{3} \right) \right] \right) \quad 26..30 \\
&+ \frac{20}{63} \cdot \left(- \left[\frac{20}{20} \cdot \log_2 \left(\frac{20}{20} \right) \right] \right) \quad 21..25 \\
&+ \frac{10}{63} \cdot \left(- \left[\frac{10}{10} \cdot \log_2 \left(\frac{10}{10} \right) \right] \right) \quad 36..40 \\
&= 0
\end{aligned}
$$

$$\text{gain(age)} = H(\text{statut}) - H(\text{statut}|\text{age}) = 0.946 - 0 = 0.946$$

Calcule split_info(dep) :

$$
\begin{aligned}
\text{split_info(dep)} &= - \sum_{x \in X} \frac{|D_x|}{|D|} \cdot \log_2 \left(\frac{|D_x|}{|D|} \right) \\
&= - \left(\frac{30}{63} \cdot \log_2 \left(\frac{30}{63} \right) \right. \quad \text{ventes} \\
&+ \frac{23}{63} \cdot \log_2 \left(\frac{23}{63} \right) \quad \text{systemes} \\
&+ \left. \frac{10}{63} \cdot \log_2 \left(\frac{10}{63} \right) \right] \quad \text{marketing} \\
&= 1.461
\end{aligned}
$$

Calcule split_info(age) :

$$
\begin{aligned}
\text{split_info(age)} &= - \sum_{x \in X} \frac{|D_x|}{|D|} \cdot \log_2 \left(\frac{|D_x|}{|D|} \right) \\
&= - \left[\frac{30}{63} \cdot \log_2 \left(\frac{30}{63} \right) \right. \quad 31..35 \\
&+ \frac{3}{63} \cdot \log_2 \left(\frac{3}{63} \right) \quad 26..30 \\
&+ \frac{20}{63} \cdot \log_2 \left(\frac{20}{63} \right) \quad 21..25 \\
&+ \left. \frac{10}{63} \cdot \log_2 \left(\frac{10}{63} \right) \right] \quad 36..40 \\
&= 1.665
\end{aligned}
$$

Calcule gain_ratio(dep) :

$$\text{gain_ratio(dep)} = \frac{\text{gain(dep)}}{\text{split_info(dep)}} = \frac{0.946}{1.461} = 0.647$$

Calcule gain_ratio(age) :

$$\text{gain_ratio(age)} = \frac{\text{gain(age)}}{\text{split_info(age)}} = \frac{0.946}{1.665} = 0.568$$

Arbre de decision de la deuxieme iteration :

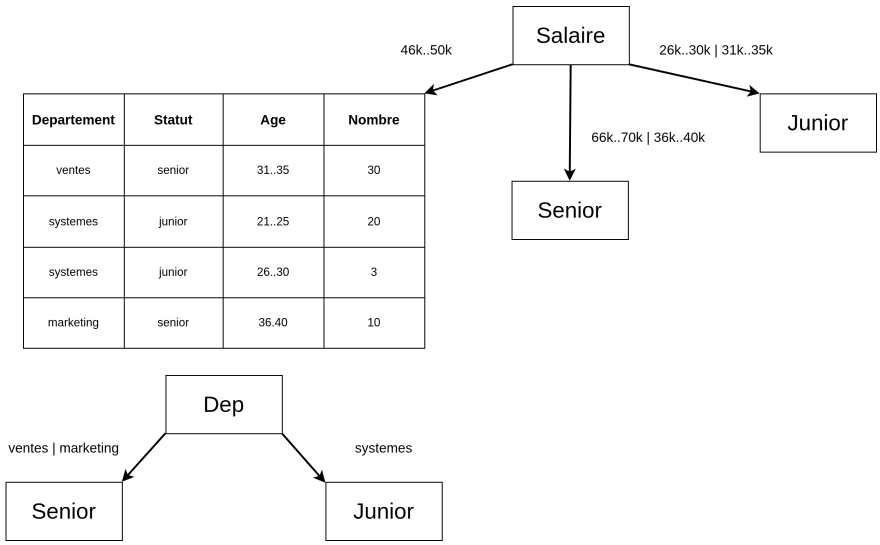

Departement	Statut	Age	Nombre
ventes	senior	31..35	30
systemes	junior	21..25	20
systemes	junior	26..30	3
marketing	senior	36.40	10